

Attention Is All You Need

注意力就是你所需要的一切 | Transformer 原论文精读，从自注意力到多头机制

时长 27:07 | 句数 526 | 术语 108 | 章节 20

摘要

本讲共 20 章，从「序列到序列模型开场」到「注意力优势与代码资源」。全文 526 句、526 句已译成中文，标注了 109 个 AI 术语（主要集中在神经网络基础、数学与微积分、训练与优化）。

20 chapters, 526 sentences (526 translated), 109 AI terms annotated. Built fully offline with opus-mt + local glossary.

序列到序列模型开场

00:00 hi there today we're looking at
大家好，今天我们要看的是

00:03 attention is all you need by Google just Google 的《Attention Is All You Need》，只是
由 Google 提出的《Attention Is All You Need》，只是

attention is all you need
《Attention Is All You Need》 Google提出Transformer的论文，主张仅用注意力。
神经网络基础

google
谷歌 论文作者所属公司，非本讲座作者雇主。
代码与工程

00:06 to declare I don't work for Google just
声明一下，我不为 Google 工作，只是

google
谷歌 论文作者所属公司，非本讲座作者雇主。
代码与工程

00:08 because we've been looking at Google
因为我们最近一直在看 Google

google
谷歌 论文作者所属公司，非本讲座作者雇主。
代码与工程

00:10 papers lately but it's just an
的论文，但它只是一篇

00:12 interesting paper and we're gonna see
有趣的论文，我们要看看

00:15 what's the deal with it so basically
它到底是怎么回事，所以基本上

00:18 what the authors are saying is we should
作者们说的是，我们应该

00:21 kind of get away from basically RNNs
基本上摆脱 RNN

00:27 so traditionally what you would do and
所以传统上你会做的是，而

00:30 these authors particular interested in
这些作者特别感兴趣的是

00:33 NLP natural language processing so
NLP，自然语言处理，所以

nlp
自然语言处理 让计算机理解与生成人类语言的领域。
神经网络基础

natural language processing
自然语言处理 NLP全称，处理文本和语言任务。
神经网络基础

传统编码器解码器回顾

00:35 traditionally when you had like a
传统上，当你有一个

00:37 language task the cat eats the mouse and
语言任务，比如“猫吃老鼠”，然后

> **language task**
> 语言任务 如翻译等需要处理自然语言的任务。
> 神经网络基础

00:46 you would like to translate this to say
你想把它翻译成比如说

00:50 any other language like let's say German
任何其他语言，比如德语

00:56 or whatever what you would do is you
之类的，你会做的是，你

01:00 would try to encode this sentence into a
会尝试把这句话编码成一个

> **encode**
> 编码 将输入句子转换为内部表示的过程。
> 神经网络基础

01:03 representation and then decode it again
表示，然后再把它解码出来

> **representation**
> 表示 用向量或张量编码输入信息。
> 神经网络基础

> **decode**
> 解码 从内部表示逐步生成目标词的过程。
> 神经网络基础

01:05 so somehow somehow this sentence needs
所以不知怎么地，这句话需要

01:10 to all go into say one vector and then
全部进入比如说一个向量，然后

vector
向量 有方向和大小的数值数组，表示特征。
数学与微积分

01:13 this one vector needs to somehow be
这一个向量需要以某种方式被

vector
向量 有方向和大小的数值数组，表示特征。
数学与微积分

01:16 transformed into the target language so
转换成目标语言，所以

target language
目标语言 翻译要生成的语言，如德语。
神经网络基础

01:20 these are tradition called seq2seq
这些传统上被称为序列到序列

seq2seq
序列到序列 将输入序列编码后解码为输出序列的框架。
神经网络基础

01:22 tasks and they have been solved so far
任务，并且到目前为止它们被解决

01:27 using recurrent neural networks you
用的是循环神经网络，你

recurrent neural networks
循环神经网络 RNN全称，用于序列建模但难以并行。
神经网络基础

01:30 might know the LSTM networks that
可能知道 LSTM 网络，它们

lstm
长短期记忆网络 带门控的RNN，缓解长程依赖问题。
神经网络基础

01:34 are very popular for these tasks what
在这些任务中非常流行。基本上

01:36 basically happens in an RNN is that you
在 RNN 中发生的是，你

rnn
循环神经网络 按时间步处理序列并传递隐藏状态的网络。
神经网络基础

01:38 go over the say source sentence here one
遍历比如说这里的源句子，一个

source sentence
源句子 待翻译或待处理的原始语言句子。
神经网络基础

隐藏状态与解码递推

01:42 by one here you take the word the you
一个地，这里你取单词 the，你

01:45 kind of encode it maybe with a word
把它编码，也许用一个词

encode
编码 将输入句子转换为内部表示的过程。
神经网络基础

01:48 vector if you know that is so you turn
向量，如果你知道的话，所以你把它

vector
向量 有方向和大小的数值数组，表示特征。
数学与微积分

01:51 it into like a vector a word vector and
变成一个向量，一个词向量，然后

vector
向量 有方向和大小的数值数组，表示特征。
数学与微积分

word vector
词向量 将单词表示为数值向量的方法。
神经网络基础

01:54 then you use a neural network to turn
然后你用一个神经网络把这个

neural network
神经网络 由多层可学习参数组成的函数逼近器。
神经网络基础

01:57 this vector into what we call a hidden
向量变成我们所说的隐藏

vector
向量 有方向和大小的数值数组，表示特征。
数学与微积分

02:00 state so this H 0 is a hidden state you
状态，所以这个 H 0 是一个隐藏状态，你

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

02:06 then take the second token here cat you
然后取第二个词元，这里的 cat，你

token
词元 文本序列中被处理的最小单位，如单词。
神经网络基础

02:12 again take it
再次取它

02:13 world vector because need to represent
词向量，因为需要

vector
向量 有方向和大小的数值数组，表示特征。
数学与微积分

02:16 it with numbers somehow so you use word
以某种方式用数字表示它，所以你使用词

02:19 vectors for that you turn this into you
向量来做这件事，你把这个变成，你

02:23 put it through the same function so here
把它穿过同一个函数，所以这里

02:25 is what it's like a little easy for
就是它，有点像一个小小的简易

02:28 encoder turn into the same function but
编码器，变成同一个函数，但

encoder
编码器 把源句子转换为隐藏表示的网络部分。
神经网络基础

02:30 this time this hidden state also gets
这一次这个隐藏状态也被

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

02:33 plugged in here so the word vector did
插入到这里，所以词向量呢

word vector
词向量 将单词表示为数值向量的方法。
神经网络基础

02:36 instead you can actually think of having
相反，你其实可以想象有一个

02:38 like a started state here a start
像起始状态，这里一个起始

02:42 usually people either learn this or just
通常人们要么学习这个，要么只是

02:45 initialize with zeros that kind of goes
用零初始化，那种东西会

initialize with zeros
零初始化 将初始隐藏状态设为全零向量。
神经网络基础

02:47 in to the encoder function so it's
进入编码器函数，所以它

encoder
编码器 把源句子转换为隐藏表示的网络部分。
神经网络基础

02:49 always really the same function and from
始终真的是同一个函数，然后从

02:54 the previous hidden state and the
前一个隐藏状态和

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

循环网络编码与解码

02:56 current word vector the encoder again
当前词向量，编码器再次

word vector
词向量 将单词表示为数值向量的方法。
神经网络基础

encoder
编码器 把源句子转换为隐藏表示的网络部分。
神经网络基础

02:59 predicts another hidden state h1 and so
预测另一个隐藏状态 h1，以此类

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

03:03 on so you take the next token you turn
推，所以你取下一个词元，你把它

token
词元 文本序列中被处理的最小单位，如单词。
神经网络基础

03:06 it into a word vector you put it through
变成一个词向量，你把它穿过

word vector
词向量 将单词表示为数值向量的方法。
神经网络基础

03:09 this thing the encoder function and of
这个东西，编码器函数，当然

encoder
编码器 把源句子转换为隐藏表示的网络部分。
神经网络基础

03:14 course this is a lot more complicated in
这在实际情况中要复杂得多，比如

03:16 actual like say an LSTM that's the
实际的比如说一个 LSTM，那是

lstm
长短期记忆网络 带门控的RNN，缓解长程依赖问题。
神经网络基础

03:18 basic principle behind it so you you end
它背后的基本原则，所以你最终

03:21 up with H 2 and here you'd have H 3 H 4
得到 H 2，这里你会有 H 3、H 4

03:25 and the last hidden state H 4 here you
而最后一个隐藏状态 H 4，这里你

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

03:29 would use this in kind of exactly the
会以几乎完全

03:31 same fashion you plug it into like a
相同的方式使用它，你把它插入一个

03:34 decoder let the decoder which would
解码器，让解码器，它会

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

03:37 output you a word D and it would also
输出给你一个单词 D，它也会

03:42 output you a next hidden state so H 5
输出给你下一个隐藏状态，所以 H 5

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

03:48 let's say let's just go on with the with
比如说，我们就继续

03:52 the listing of the states and this H 5
状态的列举，然后这个 H 5

03:56 would again go into the decoder which
会再次进入解码器，解码器

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

03:58 would output concert like so that's how
会输出像 cat 之类的东西，那就是

04:04 you would decode you basically these are
你会如何解码，基本上这些是

decode
解码 从内部表示逐步生成目标词的过程。
神经网络基础

04:06 RNNs what they do is they kind of take
RNN，它们做的是，它们取

04:09 if you look on top here they take an
如果你看上面这里，它们取一个

04:12 input a current input and they take the
输入，当前输入，并且它们取

04:15 last hidden state and they compute a new
最后一个隐藏状态，然后计算一个新的

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

04:19 hidden state in the case of the decoder
隐藏状态；在解码器的情况下

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

04:21 they take the hidden state and they take
它们取隐藏状态，并且它们取

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

04:26 kind of
某种

04:26 the previous usually the previous word
前一个，通常是前一个单词

previous word
前一个词 解码器上一步生成的词，作为当前输入。
神经网络基础

04:30 that you output you also feed this back
你输出的那个，你也把它反馈

04:32 into the decoder and they will output
到解码器中，然后它们会输出

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

04:35 the next word kind of make sense so you
下一个单词，有点道理吧，所以你

04:37 would guess that the hidden state kind
会猜到隐藏状态某种

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

04:39 of encode what the sentence means and
程度上编码了句子的意思，而

encode
编码 将输入句子转换为内部表示的过程。
神经网络基础

04:42 the last word that you output you need
你输出的最后一个单词，你需要

04:45 this because maybe for grammar right you
它，因为也许是为了语法，对吧，你

grammar
语法 语言的句法规则，解码器可学习。
神经网络基础

04:49 know what you've just output so kind of
知道你刚刚输出了什么，所以某种

04:51 the next word should be based on that
程度上下一个单词应该基于那个

04:56 of course you don't have to have to do
当然你不必非要

04:58 it exactly this way but that's kind of
完全这样做，但那就是某种

05:00 what what is RNNs did so attention is
RNN 所做的，所以 attention 是

> **attention**
> 注意力 让模型动态关注输入序列中不同位置的机制。
> 神经网络基础

05:06 a mechanism here to basically increase
这里的一个机制，基本上用来提升

05:11 the performance of the RNNs so the
RNN 的性能，所以

注意力缓解编码瓶颈

05:14 tension would do is in in this
attention 要做的是，在在

05:16 particular case if we look at the
这个特定情况下，如果我们看

05:20 decoder here if it's trying to predict
这里的解码器，如果它试图预测

> **decoder**
> 解码器 根据编码信息逐步生成输出序列的模块。
> 神经网络基础

05:24 this word for cat then or the next word
这个 cat 的词，然后或者说下一个单词

05:30 here say here it wants the next word and
这里，比如说这里它想要下一个单词，而

05:35 [Music]
【音乐】

05:37 in essence the only the only h6 the only
本质上，唯一的，唯一的 H6，唯一的

05:43 information it really has is what the
它真正拥有的信息是，

05:45 last word was german word for cat and
上一个单词是 cat 的德语单词，以及

05:48 what the hidden state is so if we look
隐藏状态是什么，所以如果我们看

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

05:52 at what word it actually should output
它实际应该输出什么单词

05:54 in the input sentence it's this here
在输入句子中，是这里这个

input sentence
输入句子 送入模型进行编码的原始句子。
神经网络基础

05:56 eats right and if we look at kind of the
eats，对吧，如果我们看某种

06:00 the information flow that this word has
这个单词必须经历的

information flow
信息流动 信息在编码器到解码器间传递的路径。
神经网络基础

06:05 to travel so first it needs to encode
信息流，所以首先它需要编码

encode
编码 将输入句子转换为内部表示的过程。
神经网络基础

06:07 into a word vector it needs to go
成词向量，它需要

word vector
词向量 将单词表示为数值向量的方法。
神经网络基础

06:09 through this encoder that's the same
穿过这个编码器，那是相同的

encoder
编码器 把源句子转换为隐藏表示的网络部分。
神经网络基础

06:10 function for all the words so nothing
函数，对所有单词都一样，所以没有

06:13 specific and we learned to the word eats
特别的，然后我们学到了单词 eats

06:15 here all right let's go through this
这里，好吧，让我们走一遍这个

06:17 hidden state traverse again into another
隐藏状态，再次穿越到另一个

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

06:20 step this hidden state because we have
步骤，这个隐藏状态，因为我们还有

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

06:22 two more tokens and then the next state
两个词元，然后是下一个状态

06:25 state then it goes all the way to the
状态，然后它一路走到

翻译词对齐与注意力

06:27 decoder where the first two words are
解码器，那里前两个单词被

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

06:31 decoded and still so this H six this
解码了，仍然，所以这个 H6，这个

06:34 hidden state somehow still needs to
隐藏状态不知怎么仍然需要

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

06:36 retain the information that now the
保留这个信息，即现在

06:40 it's somehow is kind of their world to
它以某种方式是那个词，要

06:44 be translated and that they that the
被翻译，而且它们，那个

06:48 decoder should find the German word for
解码器应该找到德语单词来对应

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

06:50 that so that's that's of course very a
它，所以那当然是一条非常

06:56 very long path or there's a lot of
非常长的路径，或者有很多

06:58 transformations involved over these all
变换参与其中，在这些所有

07:01 of these hidden states and the hidden
这些隐藏状态中，而隐藏

07:03 states not only do they need to remember
状态不仅需要记住

07:05 this particular word but all of the
这个特定的单词，还要记住所有

07:07 words and the order and so on and the
单词和顺序等等，以及

07:10 grammar Norquay the grammar you can
语法，还有语法，你

> **grammar**
> 语法 语言的句法规则，解码器可学习。
> 神经网络基础

07:13 actually learn with the decoders
其实可以用解码器

07:15 themselves but kind of the meaning and
本身来学习，但某种意义上的含义和

07:16 the structure of the sentence so it's
句子的结构，所以这

07:19 very hard for an RNN to learn all of
对 RNN 来说非常难学习所有

> **rnn**
> 循环神经网络 按时间步处理序列并传递隐藏状态的网络。
> 神经网络基础

07:22 this what they what we call long-range
这些，我们所说的长距离

07:24 dependencies and so naturally you
依赖，所以自然地你

07:28 actually think well why can't we just
其实会想，为什么我们不能就

07:30 you know decode the first word to the
你知道，把第一个单词解码到

decode
解码 从内部表示逐步生成目标词的过程。
神经网络基础

07:33 first word the second word to the second
第一个单词，第二个单词到第二个

长距离依赖学习困难

07:34 world it actually works pretty well in
单词，它其实效果很好，在

07:37 this example right like the the cat cuts
这个例子里，对吧，就像猫吃

07:40 it eats the week just decoded it one by
它吃，我们刚刚一个一个解码它

07:43 one about of course that's not how
一个，但当然那不是

07:44 translation works in translations the
翻译运作的方式，在翻译中

translation
翻译 将源语言句子转换为目标语言句子。
神经网络基础

07:46 sentences can become rearranged in the
句子可以在目标语言中

07:49 target language like one word can become
被重新排列，比如一个单词可以变成

target language
目标语言 翻译要生成的语言，如德语。
神经网络基础

07:51 many words or you could even be an
很多单词，或者甚至可以是

07:54 entirely different expression so
完全不同的表达，所以

07:57 attention is a mechanism by which this
attention 是一种机制，通过它这个

attention
注意力 让模型动态关注输入序列中不同位置的机制。
神经网络基础

07:59 decoder here in this step that we're
解码器在这里，在我们

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

08:01 looking at can actually decide to go
看的这一步，可以实际决定回

08:04 back and look at particular parts of the
去查看输入的

08:07 input especially what it would do
特定部分，尤其是它会怎么做

08:10 anything like popular attention
任何像流行的 attention

attention
注意力 让模型动态关注输入序列中不同位置的机制。
神经网络基础

08:12 mechanisms is that the dis decoder here
机制那样，就是这个解码器这里

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

08:15 would can decide to attend to the hidden
可以决定关注

08:21 states of the input sentence what that
输入句子的隐藏状态，那

input sentence
输入句子 送入模型进行编码的原始句子。
神经网络基础

解码器回看编码器状态

08:24 means is in in this particular case we
意味着，在在这个特定情况下，我们

08:26 would like to teach the decoder somehow
想以某种方式教解码器

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

08:28 that AHA look here I need to pay close
啊哈，看这里，我需要密切

08:32 attention to this step here because that
关注这一步，因为那

attention
注意力 让模型动态关注输入序列中不同位置的机制。
神经网络基础

08:36 was the step when the word eats was just
是单词 eats 刚刚

08:39 encoded so it probably has a lot of
被编码的那一步，所以它可能有很多

08:42 information about what I would like to
关于我现在想做什么的

08:45 do right now namely translate this word
信息，也就是翻译这个单词

08:49 eats so this mechanism

eats，所以这个机制

08:53 if you look at the information flow it

如果你看信息流，它

information flow
信息流动 信息在编码器到解码器间传递的路径。
神经网络基础

08:56 simply it goes through this word vector

简单地穿过这个词向量

word vector
词向量 将单词表示为数值向量的方法。
神经网络基础

08:58 goes through one encoding step and then

穿过一个编码步骤，然后

09:01 is that hidden state and then the

就是那个隐藏状态，然后

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

09:03 decoder can look directly at that so the

解码器可以直接看那个，所以

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

09:06 the path length of information is much

信息的路径长度要

path length
路径长度 信息从源词传到解码器需经过的变换步数。
神经网络基础

09:08 shorter than going through all the

短得多，比起穿过所有

09:10 hidden states in a traditional way so

隐藏状态，以传统方式，所以

09:13 that's where tension helps and the way
那就是 attention 起作用的地方，以及

09:17 that the decoder decides what to look at
解码器决定要看什么

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

09:19 is like a kind of an addressing scheme
就像一种寻址方案

addressing scheme
寻址机制 注意力用键索引隐藏状态的软寻址方式。
神经网络基础

09:23 you may know it from neural turing
你可能从 Neural Turing 中知道它

09:25 machines or or kind of other other kind
机器，或者或者另一种另一种

09:31 of neural algorithms things so what the
神经网络算法之类的东西，所以

09:35 decoder will do is in each step it would
解码器会做的是，在每一步它会

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

注意力权重归一化计算

09:37 output a bunch of keys oops sorry about
输出一堆键，哎呀，抱歉

keys
键 注意力中用于索引和匹配隐藏状态的向量。
神经网络基础

09:42 that that's my hand being trippy so what
那个，那是我的手在晃，所以

09:48 I would output is a bunch of keys so K 1
我会输出一堆键，所以 K 1

keys
键 注意力中用于索引和匹配隐藏状态的向量。
神经网络基础

09:51 through K and what would these keys
到 K，这些键会

keys
键 注意力中用于索引和匹配隐藏状态的向量。
神经网络基础

09:58 would do is they would index these
做的是，它们会索引这些

10:02 hidden kind of hidden states via a kind
隐藏的，算是隐藏状态，通过一种

10:08 of softmax architecture and we're gonna
softmax 架构，然后我们要

softmax
Softmax 把一组分数变成概率分布的指数归一化函数。
数学与微积分

10:12 look at this I think in the actual paper
看这个，我想在实际论文里

10:14 we're discussing because it's gonna
我们讨论的，因为它会

10:16 become more clear which is kind of
变得更清楚，这有点

10:19 notice that the decoder here can decide
注意这里的解码器可以决定

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

10:21 to attend it to the input sentence and
关注输入句子，并

input sentence
输入句子 送入模型进行编码的原始句子。
神经网络基础

10:25 kind of draw information directly from
算是直接从那里提取信息

10:27 there instead of having to go just to
而不是只能去看

10:30 the hidden state it's provided with so
提供给它的隐藏状态，所以

hidden state
隐藏状态 神经网络中保留历史信息的内部状态向量。
神经网络基础

10:33 if we go to the paper here what do these
如果我们到这里看论文，这些

10:36 authors propose and the thing is they
作者提出了什么，事情是，他们

10:39 teach the origins they basically say
教起源，他们基本上说

抛弃循环的注意力机制

10:42 attention is all you need you don't need
注意力就是你所需要的一切，你不需要

attention is all you need
《Attention Is All You Need》 Google提出Transformer的论文，主张仅用注意力。
神经网络基础

10:44 the entire recurrent things basically in
整个循环的东西，基本上在

10:46 every step of this decode of this and
这个解码的每一步，这个以及

decode
解码 从内部表示逐步生成目标词的过程。
神经网络基础

10:49 basically of the decoding so you want to
基本上解码的，所以你想要

10:51 produce the target sentence so in this
生成目标句子，所以在这个

target sentence
目标句子 模型已生成或待生成的目标语言句子。
神经网络基础

10:53 step in this step in this step you can
步骤，在这个步骤，在这个步骤，你可以

10:57 basically you don't need the recurrence
基本上你不需要循环

recurrence
循环 序列计算中反复使用上一步状态的性质。
神经网络基础

11:00 even just kind of do attention over
甚至可以只是对……做 attention

attention
注意力 让模型动态关注输入序列中不同位置的机制。
神经网络基础

11:03 everything and you
所有东西做注意力，然后你

11:07 be fine namely what they do is they
就会没事，也就是说他们做的是他们

11:11 propose this transformer architecture so
提出这个 Transformer 架构，所以

transformer
Transformer 完全基于注意力、可并行处理的序列模型架构。
神经网络基础

11:14 what does it do it has two parts what's
它做什么，它有两部分，什么

11:18 what's called an encoder and a decoder
叫做编码器和解码器

encoder
编码器 把源句子转换为隐藏表示的网络部分。
神经网络基础

decoder
解码器 根据编码信息逐步生成输出序列的模块。
神经网络基础

11:20 but don't kind of be confused um because
但别搞混了，呃，因为

11:27 this all happens at once so this is not
这一切都同时发生，所以这不是

11:29 an art and it all happens at once every
一种艺术，而且都同时发生，每个

11:32 all the source sentence so if we again
整个源句子，所以如果我们再次

source sentence
源句子 待翻译或待处理的原始语言句子。
神经网络基础

11:35 have the cat oops that doesn't work as
有猫，哎呀，这不太好用

自注意力编码解码架构

11:40 easy let's just do this this is a source
简单点，我们就这样做，这是一个源

11:44 sentence and then we also have a target
句子，然后我们还有一个目标

11:46 sentence that maybe we've produced two
句子，也许我们已经生成了两个

11:49 words and we want to produce this third
词，我们想生成这第三个

11:52 word here what a produces so we would
词，在这里，产生了什么，所以我们会

11:56 feed the entire source sentence and also
喂入整个源句子，还有

source sentence
源句子 待翻译或待处理的原始语言句子。
神经网络基础

12:00 the targets and as we produced so far to
目标，以及我们到目前为止生成的，给

12:03 this network namely the source sentence
这个网络，即源句子

source sentence
源句子 待翻译或待处理的原始语言句子。
神经网络基础

12:05 would go into this part and the target
会进入这一部分，而目标

12:09 that we've produced so far would go into
我们到目前为止生成的会进入

12:11 this part and this is the all combined
这一部分，这是全部组合起来

12:15 and at the end we get an output here at
最后我们在这里得到一个输出，在

12:20 the output probabilities that kind of
输出概率，那种

output probabilities
输出概率 模型对下一个词给出的概率分布。
训练与优化

12:23 tells us the probabilities for the next
告诉我们下一个词的概率

12:25 word so we can choose the top
词，所以我们可以选择最高

12:28 probability and then repeat the entire
概率，然后重复整个

12:31 process so basically every step in
过程，所以基本上每一步

12:34 production is one training sample every
生成都是一个训练样本，每个

> **one training sample**
> 单步训练样本 Transformer中生成一个词元即一个训练样本。
> 训练与优化

12:38 step in producing a sentence here before
在这里生成句子的步骤，之前

12:39 with the Orang ends the entire sentence
随着 Orang 结束整个句子

12:42 to sentence translation is one sample
到句子翻译是一个样本

> **translation**
> 翻译 将源语言句子转换为目标语言句子。
> 神经网络基础

12:44 because we need to back propagate
因为我们需要反向传播

12:46 through all of these RNN in steps
遍历所有这些 RNN 步骤

> **rnn**
> 循环神经网络 按时间步处理序列并传递隐藏状态的网络。
> 神经网络基础

12:48 because they all happen kind of in
因为它们都算是在

序列建模范式转变

12:50 sequence here basically output of one
这里的序列基本上是一个……的输出

sequence
序列 按顺序排列的词元或向量集合。
神经网络基础

12:54 single token is one sample and then the
单个 token 是一个样本，然后

token
词元 文本序列中被处理的最小单位，如单词。
神经网络基础

12:58 computation is finished the back drop
计算就完成了，反向传播

12:59 happens through everything only for this
只对这

13:02 one step there is no multi-step kind of
一个步骤贯穿所有东西，没有多步的

13:05 back propagation as in RNN and this
反向传播，就像在 RNN 中那样，而这是

back propagation
反向传播 根据损失沿计算图回传梯度更新参数。
反向传播与梯度

rnn
循环神经网络 按时间步处理序列并传递隐藏状态的网络。
神经网络基础

13:09 is kind of a paradigm shift in sequence
序列处理中的一种范式转变

paradigm shift
范式转变 从循环网络转向纯注意力架构的转变。
神经网络基础

sequence
序列 按顺序排列的词元或向量集合。
神经网络基础

13:13 processing because people were always
因为人们一直

13:15 convinced that you kind of need these
相信你有点需要这些

13:18 recurrent things in order to
循环的东西，才能

13:20 to make good to learn these dependencies
做好，才能学习这些依赖关系

13:24 but here they basically say Nenana
但这里他们基本上说 Nenana

13:25 we can just do attention over everything
我们可以直接对所有东西做注意力

attention
注意力 让模型动态关注输入序列中不同位置的机制。
神经网络基础

13:28 and little bit will actually be fine if
而且一点点实际上就会没事，如果

13:30 we just do one step projections so let's
我们只做一步投影，所以让我们

one step projections
单步投影 Transformer每步仅做一次投影计算，不循环。
神经网络基础

13:34 go one by one so here with an input
一个一个来，所以这里有一个输入

13:37 embedding and say an output embedding
嵌入，比如一个输出嵌入

output embedding
输出嵌入 将目标句子词元转换为向量的层。
神经网络基础

13:40 these these are symmetrical so basically
这些这些是对称的，所以基本上

词元嵌入与位置编码

13:43 the tokens just get embedded with say
token 只是被嵌入，比如用

13:45 word vectors again then there's a
词向量，然后有一个

13:48 positional encoding this is kind of a
位置编码，这是一种

positional encoding
位置编码 用三角函数为词元注入位置信息的编码。
神经网络基础

13:49 special thing where because you know
特殊的东西，因为你知道

13:53 lose this kind of sequence nature of
失去了这种序列性质

sequence
序列 按顺序排列的词元或向量集合。
神经网络基础

13:56 your algorithm you kind of need to
你的算法，你有点需要

13:57 encode where the words are that you push
编码你推入的单词在哪里

encode
编码 将输入句子转换为内部表示的过程。
神经网络基础

14:01 through the network so the network kind
通过网络，所以网络有点

14:02 of goes AHA this is a word at the
会说啊哈，这是句首的

14:03 beginning of the sentence or is the word
一个词，或者这个词

14:05 towards the end of the sentence so or
在句子末尾，所以或者

14:07 that it can compare to words like which
它可以和单词比较，比如哪个

14:10 one comes first
先来

14:11 which one comes second and you do this
哪个第二，你这样做

14:14 it's pretty easy for the networks if you
对网络来说很容易，如果你

14:16 do it with kind of these trigonometric
用这些三角

14:19 functioning embeddings so if I draw your
函数嵌入来做，所以如果我给你画

14:22 sine wave and I don't need a sine wave
正弦波，我不需要正弦波

sine wave
正弦波 位置编码中用于表示不同频率的波形。
数学与微积分

14:24 of that a stop was fast and I draw you a
那个停得太快了，我给你画一个

14:30 sine wave that is even faster maybe this
更快的正弦波，也许这个

sine wave
正弦波 位置编码中用于表示不同频率的波形。
数学与微积分

14:34 one actually sync one two three four
一个实际上同步，一 二 三 四

14:37 five doesn't matter you know what I mean
五，无所谓，你懂我的意思

14:40 so I can encode the first world you can
所以我可以编码第一个词，你可以

encode
编码 将输入句子转换为内部表示的过程。
神经网络基础

14:44 encode the first position with all down
编码第一个位置，全是下

encode
编码 将输入句子转换为内部表示的过程。
神经网络基础

14:47 and then the second position is kind of
然后第二个位置算是

14:50 down down up and the third position is
下下上，第三个位置是

14:55 kind of up down up and so on so this is
算是上下上，等等，所以这是

14:59 kind of a continuous way of binary
一种连续的二进制

15:02 encoding of position so if I want to
位置编码，所以如果我想

15:05 compare two words I can just look at all
比较两个词，我可以看所有

位置编码缩放与拼接

15:07 the scales of these things and I know
这些东西的尺度，我知道

15:10 how this word one word has high here and
这个词，一个词在这里高，而

15:13 the other word is low here so they must
另一个词在这里低，所以它们一定

15:14 be pretty far away like one must be at
离得挺远，比如一个一定在

15:17 the beginning and one must be at the end
开头，一个一定在末尾

15:19 if they happen to match in this long
如果它们碰巧在这个长

15:23 rate long wave and they also are both
率长波中匹配，而且它们也都

15:25 kind of low in this wave and then I can
算是这个波中低，然后我可以

15:29 look in this way for like oh maybe
这样看，比如哦也许

15:32 they're close together but here
它们靠得很近，但这里

15:33 I really got the information which ones
我真的得到了信息，哪个

15:35 first which was second so these are kind
第一，哪个第二，所以这些算是

15:38 of positional encodings they they're not
位置编码，它们它们不是

15:40 critical to this algorithm but they just
对这个算法关键，但它们只是

15:45 encode where the words are which of
编码单词在哪里，这当然

encode
编码 将输入句子转换为内部表示的过程。
神经网络基础

15:47 course that is important and it gives
很重要，它给

15:50 the networking a significant boost in
网络带来显著提升

15:52 performance but it's not like it's not
性能，但并不是说它不是

15:56 that the meat of the thing the meat of
事情的核心，核心

15:58 the thing is that now that these
是现在这些

16:02 encoding is go into the network's they
编码进入网络，它们

16:05 simply do what they call tension here
只是做他们这里叫做 tension 的东西

16:09 attention here and attention here so
这里注意力，这里注意力，所以

attention
注意力 让模型动态关注输入序列中不同位置的机制。
神经网络基础

16:13 there's kind of three kinds of attention
算是有三种注意力

attention
注意力 让模型动态关注输入序列中不同位置的机制。
神经网络基础

多头注意力层结构

16:16 so basically the first attention on the
所以基本上第一个注意力在

attention
注意力 让模型动态关注输入序列中不同位置的机制。
神经网络基础

16:18 bottom left is simply attention as you
左下角，就是注意力，如你

attention
注意力 让模型动态关注输入序列中不同位置的机制。
神经网络基础

16:21 can see over the input sentence so if I
所见，作用在输入句子上，所以如果我

input sentence
输入句子 送入模型进行编码的原始句子。
神经网络基础

16:25 told you before you need to take this
之前告诉你，你需要拿这个

16:27 input sentence if you look over here and
输入句子，如果你看这里，并且

input sentence
输入句子 送入模型进行编码的原始句子。
神经网络基础

16:29 you somehow need to encode it into a
你以某种方式需要把它编码成

encode
编码 将输入句子转换为内部表示的过程。
神经网络基础

16:32 hidden representation and this now looks
隐藏表示，而这现在看起来

hidden representation
隐藏表示 模型对输入编码后得到的内部向量表示。
神经网络基础

16:38 much more like the picture I drew here
更像我这里画的图

16:40 in the picture I drew right at the
在我画的图里，就在

16:41 beginning is that all at once I kind of
一开始，就是我一下子算是

16:44 put together this head representation
组合出这个头表示

representation
表示 用向量或张量编码输入信息。
神经网络基础

16:46 and all you do is he used attention over
而你所做的就是，他对……使用注意力

attention
注意力 让模型动态关注输入序列中不同位置的机制。
神经网络基础

16:49 the input sequence which basically means
输入序列，这基本上意味着

input sequence
输入序列 模型按顺序处理的输入词元序列。
神经网络基础

16:51 you kind of pick and choose which word
你有点挑选哪个词

16:53 you look at more or less so with the
你或多或少看，所以对于

16:57 bottom right so in the the output
右下角，所以在输出

16:59 sentence that you've produced so for
你已经生成的句子，所以例如

17:00 example a encoded into kind of a hidden
一个编码成一种隐藏

17:03 state and then the third on the top
状态，然后第三个在顶部

17:06 right that's the I think that sorry I
右边，那是我想，那个，抱歉我

17:10 got interrupted so as are saying the top
被打断了，所以正如所说，顶部

17:13 right is the most interesting part of
右边是这里最有趣的部分

17:16 the attention mechanism here where
这里的注意力机制，其中

attention
注意力 让模型动态关注输入序列中不同位置的机制。
神经网络基础

17:19 basically it unites the kind of encoder
基本上它把那种编码器

encoder
编码器 把源句子转换为隐藏表示的网络部分。
神经网络基础

编码解码注意力连接

17:23 part with the kind of beak let's not it
部分和一种喙结合起来，我们别，它

17:25 combines the source sentence with the
把源句子和

source sentence
源句子 待翻译或待处理的原始语言句子。
神经网络基础

17:28 target sentence that you've produced so
你已经生成的目标句子，到目前为止

target sentence
目标句子 模型已生成或待生成的目标语言句子。
神经网络基础

17:31 far so as you can see maybe here I can
所以如你所见，也许这里我可以

17:37 just slightly annoying but I'm just
只是有点烦人，但我只是

17:43 gonna remove these kind of circles here
要移除这里这些圆圈

17:46 so
所以

17:47 if you can see here there is an output
如果你能看这里，有一个输出

17:51 going from the part that encodes the
从那个编码……的部分出来

17:54 source sentence and it goes into this
源句子，然后它进入这个

source sentence
源句子 待翻译或待处理的原始语言句子。
神经网络基础

17:57 multi-head attention there's two
多头注意力，有两个

multi-head attention
多头注意力 并行运行多组注意力以捕捉不同子空间信息。
神经网络基础

18:00 connections and there's also one
连接，还有一个

18:02 connection coming from the encoded
连接来自已编码的

18:06 output so far here and so there's three
到目前为止的输出，这里，所以有三个

18:12 connections going in going into this and
连接进入这个，然后

18:15 we're gonna take a look at what these
我们要看看这些

18:18 three connections are so the the three
三个连接是什么，所以这三个

18:22 connections here basically are the keys
连接基本上就是键

keys
键 注意力中用于索引和匹配隐藏状态的向量。
神经网络基础

查询键值点积计算

18:26 values and queries if you see here the
如果你在这里看到 值 和 查询，那么

values
值 注意力中与键关联、被加权汇总的信息向量。
神经网络基础

queries
查询 注意力中用来检索相关键值对的向量。
神经网络基础

18:31 values and the keys are what is output
值 和 键 是输出的东西

values
值 注意力中与键关联、被加权汇总的信息向量。
神经网络基础

keys
键 注意力中用于索引和匹配隐藏状态的向量。
神经网络基础

18:36 by the encoding part of the source
由源句子的编码部分

encoding part
编码部分 网络中负责把输入变成隐藏表示的组件。
神经网络基础

18:38 sentence and the query is output by the
句子，而查询是由

18:41 encoding part of the target sentence and
目标句子的编码部分输出，并且

encoding part
编码部分 网络中负责把输入变成隐藏表示的组件。
神经网络基础

target sentence
目标句子 模型已生成或待生成的目标语言句子。
神经网络基础

18:45 these are not only one value key in
这些不只是一个值键在

18:48 query so there are many and this kind of
查询中，所以有很多，这种

18:51 multi-head attention fashion so there
多头注意力方式，所以

multi-head attention
多头注意力 并行运行多组注意力以捕捉不同子空间信息。
神经网络基础

18:54 are just many of them instead of one but
它们只是很多个，而不是一个，但

18:55 you can think of and as there's just
你可以把 and 想成只是有

18:59 kind of sets so the attention computed
某种集合，所以这里计算的注意力

attention
注意力 让模型动态关注输入序列中不同位置的机制。
神经网络基础

19:02 here is what does it do so first of all
它是做什么的呢，首先

19:05 it calculates a dot product of the
它计算键和查询的点积

dot product
点积 两向量对应元素乘积之和，衡量相似度。
数学与微积分

19:09 keys and the queries and then it is a
键和查询，然后它是一个

keys
键 注意力中用于索引和匹配隐藏状态的向量。
神经网络基础

queries
查询 注意力中用来检索相关键值对的向量。
神经网络基础

19:13 softmax over this and then it
对此做 softmax，然后它

softmax
Softmax 把一组分数变成概率分布的指数归一化函数。
数学与微积分

19:16 multiplies it by the value so what does
将它乘以值，那么

19:17 this do if you dot product the keys
这做了什么，如果你对键做点积

dot product
点积 两向量对应元素乘积之和，衡量相似度。
数学与微积分

keys
键 注意力中用于索引和匹配隐藏状态的向量。
神经网络基础

19:22 and the queries what you would get is so
和查询，你会得到的是

queries
查询 注意力中用来检索相关键值对的向量。
神经网络基础

19:26 as you know if you have two vectors and
如你所知，如果你有两个向量

19:29 the dot there dot product basically
点积，那里的点积基本上

dot product
点积 两向量对应元素乘积之和，衡量相似度。
数学与微积分

19:31 gives you the angle between the vectors
给出向量之间的角度

19:35 with especially in high dimensions most
尤其在高维中，大多数

high dimensions
高维空间 向量维度很高的空间，随机向量近似正交。
数学与微积分

19:38 vectors going to be of kind of a 90
向量会差不多是 90

19:42 degree kind of I know the Americans
度那样，我知道美国人

19:45 doodle the little square
画那个小方块

19:49 so most vectors are going to be not
所以大多数向量不会

19:51 aligned very well so their dot product
对齐得很好，所以它们的点积

aligned
对齐 两个向量方向相近、点积较大的状态。
数学与微积分

dot product
点积 两向量对应元素乘积之和，衡量相似度。
数学与微积分

19:53 will kind of be zero ish but if a key in
会差不多是零，但如果一个键和

19:57 the query actually aligned with each
查询实际上彼此对齐

aligned
对齐 两个向量方向相近、点积较大的状态。
数学与微积分

19:59 other like
就像

20:01 if they point into the same directions
如果它们指向相同方向

20:04 the dot product will actually be large
点积实际上会很大

dot product
点积 两向量对应元素乘积之和，衡量相似度。
数学与微积分

20:07 so what you can think of this as the the
所以你可以把这看作

20:11 keys are kind of here the keys are just
键大概在这里，键只是

keys
键 注意力中用于索引和匹配隐藏状态的向量。
神经网络基础

20:13 a bunch of vectors in space and each key
空间中的一堆向量，每个键

20:19 has an Associated value so each key
都有一个关联的值，所以每个键

键值表与注意力选择

20:22 there is a kind of a table value one
那里有一种表格，值 1

20:26 value to value three this is really
值 2、值 3，这真的

20:31 annoying if I do this over text right so
很烦，如果我在文本上做这个，对吧，所以

20:34 again here so we have a bunch of keys
再次这里，所以我们有一堆键

> **keys**
> 键 注意力中用于索引和匹配隐藏状态的向量。
> 神经网络基础

20:37 right in space and with a table with
就在空间中，带有一个表格，表格里

20:41 values and each key here corresponds to
有值，这里的每个键对应

> **values**
> 值 注意力中与键关联、被加权汇总的信息向量。
> 神经网络基础

20:44 a value value one value to value three
一个值，值 1、值 2、值 3

20:47 value 4 and so each key is associated
值 4，所以每个键都关联

20:51 with one of these values and then when
这些值之一，然后当

values
值 注意力中与键关联、被加权汇总的信息向量。
神经网络基础

20:54 we introduce a query what can it do so
我们引入一个查询，它能做什么呢

20:57 query will be a vector like this and we
查询会是一个像这样的向量，我们

vector
向量 有方向和大小的数值数组，表示特征。
数学与微积分

21:01 simply compute D so this is Q this is
简单地计算 D，所以这是 Q，这是

21:04 the query we compute the dot product
查询，我们计算点积

dot product
点积 两向量对应元素乘积之和，衡量相似度。
数学与微积分

21:06 with each of the keys and and then we
与每个键，然后我们

keys
键 注意力中用于索引和匹配隐藏状态的向量。
神经网络基础

21:12 compute a softmax over this which means
对此计算 softmax，这意味着

softmax
Softmax 把一组分数变成概率分布的指数归一化函数。
数学与微积分

21:14 that one key will basically be selected
基本上会选中一个键

21:18 so in this case it would be probably
所以在这个情况下，可能是

21:20 this blue key here that has the biggest
这里的这个蓝色键，它有最大的

21:23 dot product with the query so this is
与查询的点积，所以这是

dot product
点积 两向量对应元素乘积之和，衡量相似度。
数学与微积分

21:27 key to in this in this case and the
在这个情况下的键 2，而

21:31 softmax so if you if you don't know what
softmax，所以如果你不知道

softmax
Softmax 把一组分数变成概率分布的指数归一化函数。
数学与微积分

21:33 a softmax is you have you have like X 1
softmax 是什么，你有，你有像 X 1

softmax
Softmax 把一组分数变成概率分布的指数归一化函数。
数学与微积分

21:35 2 X and B like some numbers then you
2 X 和 B 这样的一些数字，那么你

21:38 simply do you map them to the
简单地做，你将它们映射到

21:42 exponential function each one of them
指数函数，它们每一个

exponential function
指数函数 以 e 为底的函数，Softmax 中放大差异。
数学与微积分

21:46 and but also each one of them you divide
而且它们每一个你除以

21:49 by the sum of over over I of e to the X
对 I 求和 e 的 X

21:54 I so basically and this is a
I 次方，所以基本上，这是一个

21:55 renormalization basically you you do the
重新归一化，基本上你你做的

renormalization
重归一化 把指数化后的数值除以总和变成概率。
数学与微积分

21:58 exponential function of the numbers
是数字的指数函数

exponential function
指数函数 以 e 为底的函数，Softmax 中放大差异。
数学与微积分

22:00 which of course this makes the kind of
这当然会让那种

22:02 big numbers even bigger so basically
大数字变得更大，所以基本上

22:05 what you end up with is one of these
你最终得到的是这些

22:08 numbers x1 through xn will become very
数字 x1 到 xn 中的一个会变得非常

22:12 big compared to the others
大，相比其他数字

22:14 and then you renormalize so basically
然后你重新归一化，所以基本上

22:17 one of them will be almost one and the
它们中一个会几乎是一，而

22:18 other ones will be almost zero simply
其他几个会几乎是零，简单说

22:21 the the maximum function you can think
最大值函数，你可以把它想成

maximum function
最大值函数 选取最大元素的函数，Softmax 是其可微近似。
数学与微积分

22:23 of in a differentiable way I mean it
一种可微分的方式，我的意思是它

differentiable
可微的 函数处处有梯度，可用反向传播训练。
反向传播与梯度

22:25 should just want to select the biggest
应该只是想选出最大的

22:27 entry in this case here we kind of
项，在这个情况下，我们差不多

注意力索引与值组合

22:30 select the key that aligns most with the
选出与查询最对齐的键

22:32 query which in this case would be key
查询，在这个情况下会是键

22:33 too and then we when we multiply this
2，然后当我们把这个

22:36 softmax thing with the with the values
带有这些值的 softmax 操作

softmax
Softmax 把一组分数变成概率分布的指数归一化函数。
数学与微积分

values
值 注意力中与键关联、被加权汇总的信息向量。
神经网络基础

22:39 so this query this this inner product if
所以这个查询，这个内积，如果

inner product
内积 向量间的乘积和，可表示方向和相似性。
数学与微积分

22:46 we multiply Q with K to as an inner
我们把 Q 与 K 2 相乘作为内

22:50 product and we take the softmax over it
积，然后对它取 softmax

softmax
Softmax 把一组分数变成概率分布的指数归一化函数。
数学与微积分

22:56 softmax what we'll do is i'm going to
softmax，我们要做的是，我将要

softmax
Softmax 把一组分数变成概率分布的指数归一化函数。
数学与微积分

22:59 draw it upwards here we're going to
把它往上画，这里我们要

23:00 induce a distribution like this and if
诱导出像这样的分布，如果

distribution
分布 注意力权重形成的概率分布。
数学与微积分

23:05 we multiply this by the value it will
我们把它乘以值，它会

23:07 basically select value two so this is
基本上选出值 2，所以这是

23:12 this is kind of an indexing scheme into
这是一种索引方案，进入

indexing scheme
索引方案 用键来寻址和选择值的方式。
神经网络基础

23:15 this memory of values and this is what
这个值的记忆，而这就是

memory of values
值记忆 注意力中存放可被查询索引的值集合。
神经网络基础

23:19 then the network uses to compute further
然后网络用来计算进一步

23:22 things using so you see the output here
东西的东西，所以你看到这里的输出

23:25 goes into kind of more layers of the
进入更多层

layers
层 神经网络中依次堆叠的计算模块。
神经网络基础

23:28 neural network upwards so basically what
神经网络向上，所以基本上

neural network
神经网络 由多层可学习参数组成的函数逼近器。
神经网络基础

23:32 what you can think what does this mean
你可以想，这是什么意思

23:34 you can think of here's the whoops deep
你可以想，这里是，哎呀，深

23:38 I want to delete this you can think of
我想删掉这个，你可以想

23:43 this as basically the encoder of the
这基本上是编码器，属于

encoder
编码器 把源句子转换为隐藏表示的网络部分。
神经网络基础

23:46 source sentence right here discovers
源句子，就在这里，发现

source sentence
源句子 待翻译或待处理的原始语言句子。
神经网络基础

23:52 interesting things that looks ugly it
有趣的东西，那看起来丑，它

23:57 discovers interesting things about the
发现关于

23:59 about the source sentence and it builds
关于源句子的有趣东西，然后它构建

source sentence
源句子 待翻译或待处理的原始语言句子。
神经网络基础

24:03 key value pairs and then the encoder of
键值对，然后编码器，对

encoder
编码器 把源句子转换为隐藏表示的网络部分。
神经网络基础

24:07 the target sentence builds the queries
目标句子构建查询

target sentence
目标句子 模型已生成或待生成的目标语言句子。
神经网络基础

queries
查询 注意力中用来检索相关键值对的向量。
神经网络基础

24:10 and together they give you kind of the
它们一起给你那种

24:13 next the next signal so it means that
下一个，下一个信号，所以这意味着

24:17 the network basically says here's a
网络基本上说，这里有一

24:20 bunch of things here is a here's a bunch
堆东西，这里有一个，这里有一堆

24:22 of things about the source sentence
关于源句子的东西

source sentence
源句子 待翻译或待处理的原始语言句子。
神经网络基础

24:27 that you might find interesting that's
你可能觉得有趣，那就是

24:29 the values and the keys are ways to
值，而键是方式

values
值 注意力中与键关联、被加权汇总的信息向量。
神经网络基础

keys
键 注意力中用于索引和匹配隐藏状态的向量。
神经网络基础

24:35 index the values so it says here's a
索引这些值，所以它说这里有一

values
值 注意力中与键关联、被加权汇总的信息向量。
神经网络基础

24:38 bunch of things that are interesting
堆有趣的东西

24:40 which are the values and here is how you
也就是值，而这里是你如何

values
值 注意力中与键关联、被加权汇总的信息向量。
神经网络基础

24:42 would address these things which is the
寻址这些东西，也就是

24:44 keys and then the other part of the
键，然后另一部分

keys
键 注意力中用于索引和匹配隐藏状态的向量。
神经网络基础

24:48 network builds the queries it says I
网络构建查询，它说，我

queries
查询 注意力中用来检索相关键值对的向量。
神经网络基础

24:51 would like to know certain things so
想知道某些东西，所以

24:55 think of the value is like attributes
把值想成属性

attributes
属性 被编码为值向量的对象特征，如姓名、身高。
神经网络基础

24:57 like here is the name and the the kind
比如这里是名字，以及那种

25:01 of tallness and the weight of a person
身高和一个人的体重

25:03 right and the keys are like that the
对，而键就像那样，那个

keys
键 注意力中用于索引和匹配隐藏状态的向量。
神经网络基础

25:06 actual index is like name height weight
实际索引就像名字、身高、体重

25:10 and then the other part of the network
然后网络的另一部分

25:13 can decide what I want I actually want
可以决定我想要什么，我实际上想要

25:16 the name so my query is the name it will
名字，所以我的查询是名字，它会

25:18 be aligned with the key name and the
与键名字对齐，而

aligned
对齐 两个向量方向相近、点积较大的状态。
数学与微积分

25:21 corresponding value would be the name of
对应的值会是名字，属于

25:23 the person you would like to describe so
你想描述的人，所以

25:25 that's how kind of these networks work
这就是这些网络如何

25:27 together and I think it's a it's a
一起工作，我觉得这是一个，这是一个

25:30 pretty ingenious it's not entirely new
相当巧妙，它不完全是新的

25:33 because it has been done of course
因为它当然已经被做过

25:34 before with all the differentiable
之前，用所有可微分

differentiable
可微的 函数处处有梯度，可用反向传播训练。
反向传播与梯度

25:36 Turing machines and whatnot but it's
图灵机之类的，但它

25:40 pretty cool that this actually works and
相当酷，这居然能工作，而且

注意力优势与代码资源

25:41 actually works kind of better than our
实际上工作得比 RNNs 好一些

25:45 it ends if you simply do this so they
如果你只是做这个，所以他们

25:50 describe a bunch of other things here I
描述了一堆其他东西，这里我

25:52 I don't think they're too important
我觉得它们不太重要

25:56 basically that the point they make about
基本上他们关于

25:58 this attention is that it reduces path
这个注意力的观点是，它减少路径

> **attention**
> 注意力 让模型动态关注输入序列中不同位置的机制。
> 神经网络基础

26:01 lengths and kind of that's the the main
长度，差不多这是主要的

26:03 reason why it should work better with
原因，为什么它应该更好地工作，用

26:07 this entire attention mechanism you
这整个注意力机制，你

> **attention**
> 注意力 让模型动态关注输入序列中不同位置的机制。
> 神经网络基础

26:10 reduce the amount of computation steps
减少了计算步骤的数量

> **computation steps**
> 计算步数 信息在网络中传播所需经过的操作次数。
> 训练与优化

26:13 that information has to flow from one
信息必须从一个

26:16 point in the network to another and that
网络点流到另一个，而那就是

26:19 what brings the major improvement
带来主要改进的东西

26:21 because all the computation steps can
因为所有计算步骤都可能

computation steps
计算步数 信息在网络中传播所需经过的操作次数。
训练与优化

26:24 make you lose information and you don't
让你丢失信息，而你不

26:26 want that you want short path lengths
想要那样，你想要短路径长度

path length
路径长度 信息从源词传到解码器需经过的变换步数。
神经网络基础

26:28 and so that's that's what this method
所以那就是这个方法

26:31 achieves and they claim that's why it's
实现的东西，他们声称这就是为什么它

26:34 better and it works so well so they have
更好，它工作得这么好，所以他们有

26:39 experiments you can look at them they're
实验，你可以看看，它们

26:41 really good at everything of course of
当然在所有事情上都非常好，当然

26:45 course you're always have state of the
当然你总是有最先进

26:47 art and I think I will conclude here if
的技术，我想我会在这里总结，如果

26:53 you want to check it out yourself
你想自己查看

26:55 they have extensive code on github where
他们在 GitHub 上有大量代码，在那里

github
GitHub 托管 Transformer 实现代码的代码托管平台。
代码与工程

26:58 you can build your own transformer
你可以构建自己的 transformer

transformer
Transformer 完全基于注意力、可并行处理的序列模型架构。
神经网络基础

26:59 networks and with that have a nice day
网络，就这样，祝你今天愉快

27:04 and see ya
再见

点击任意句子从该处播放 · 空格 播放/暂停 · T 中文 · C 连播 · ↑ ↓ 上下句 · Esc 停止
字幕由 ASR 转录并经 AI 校正重译，术语释义仅供参考。